スプレッドシートを用いたデータ解析における情報要求分析

筑波大学: 丸田 敦貴, 田貝 奈央, 加藤 誠

214041 中村拓実

原論文

https://confit.atlas.jp/guide/event-img/deim2024/T3-B-3-03/public/pdf?type=in

気になった理由

情報要求に対して人はどのようなアクションを取るのか？という問題に対する研究

例えば、この情報要求については検索をする。ということがわかれば、
どのような**Web**サイトに需要があるのか、また**Web**サイトはどのような情報を提供すべきかがわかる

→ 自分の仕事領域と関連する研究

はじめに結論

まとめ 24

研究目的

スプレッドシートを用いたデータ解析中に生まれる情報要求の調査

手法: ユーザ実験を行いデータを収集し，収録映像をコーディング

分析結果

1. 6種類の情報要求（テキスト，数値，メタデータ，データ傾向，根拠，解析方法）があり，それぞれの要求を満たすための難易度は異なっている
2. ユーザはカテゴリごとに異なる検索行動をとり，特に「根拠」と「解析方法」を満たすために，異なる困難に直面する
3. 生まれるタイミングはユーザ行動（Web検索，スプレッドシート閲覧など）と関係がある

考察

ユーザの行動から生まれやすい情報要求カテゴリを特定し，そのカテゴリを満たすための情報を提供することが効果的なデータ解析につながる

出典: Zoom発表資料

研究目的

スプレッドシートを用いたデータ解析における情報要求分析を行う

- データ駆動の意思決定は重要
- スプシは直感的なデータ操作が可能なツール
- スプシはデータ解析の知識不足を一部補うことが可能,一方スプレッドシート自体の理解や分析結果の正確な解釈のために，多様な知識（ドメイン知識や分析方法の知識など）が必要
- ↑ユーザはスプレッドシート理解のために約 40%の時間を情報探索に費やしている(先行研究)
- 直感的なデータ分析のためには、ユーザの情報要求を理解することが重要

リサーチクエスチョン(RQ)

スプレッドシートを用いたデータ解析中にどのような情報要求が生まれるのか？

スプレッドシートを用いたデータ解析中の情報要求を満たすためにユーザはどのように検索するのか？

スプレッドシートを用いたデータ解析において，いつ情報要求が生まれるのか？

要するに、**いつ なにを どうやって** 検索するのか？

実験方法

- 対象: 36人の大学院生
- タスク: スプレッドシートを使用してデータを分析し、その結果をまとめたレポートを作成
- 条件: 参加者は、データ解析プロセス中に生じる情報要求を探求するため、思考発話法を用いて自身の考えを声に出して述べる
- 分類手法: 初期の情報要求の分類法は文献調査に基づいて作成され、収集した情報要求の実例を用いて改善
- 評価: タスク終了後のインタビューを通じて、各情報要求に対する主観的な満足度と検索の難易度についてのデータを収集

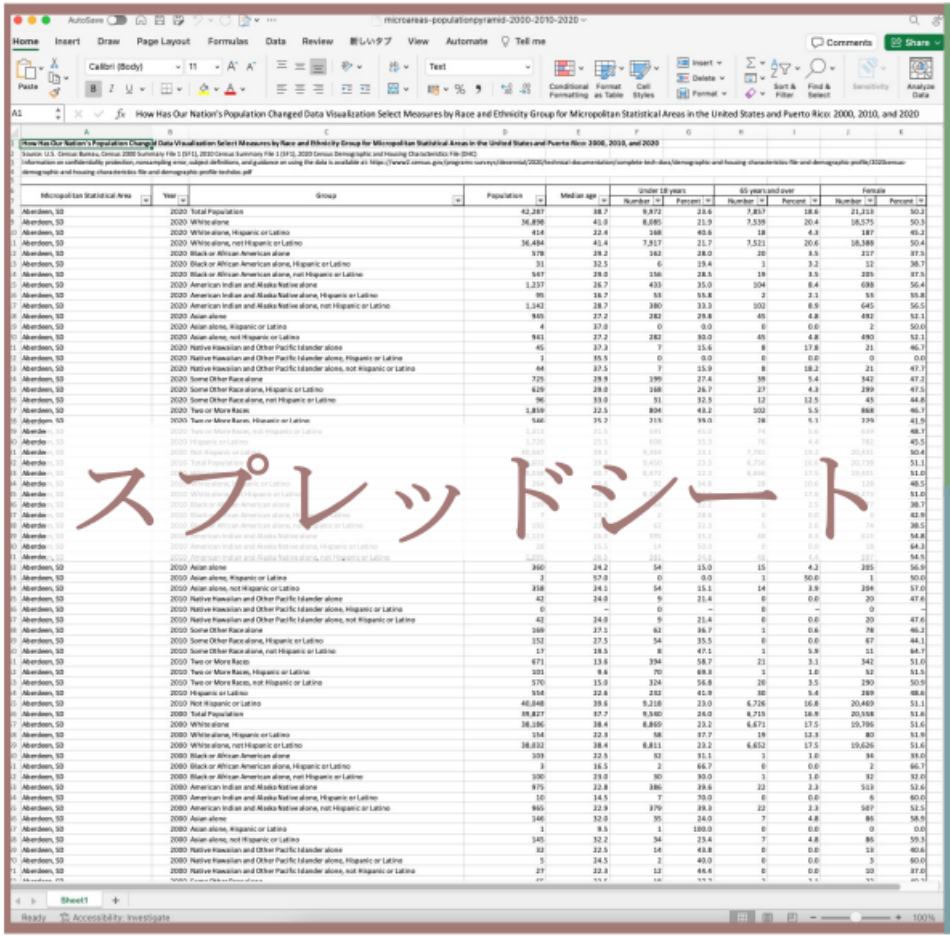
スプレッドシート

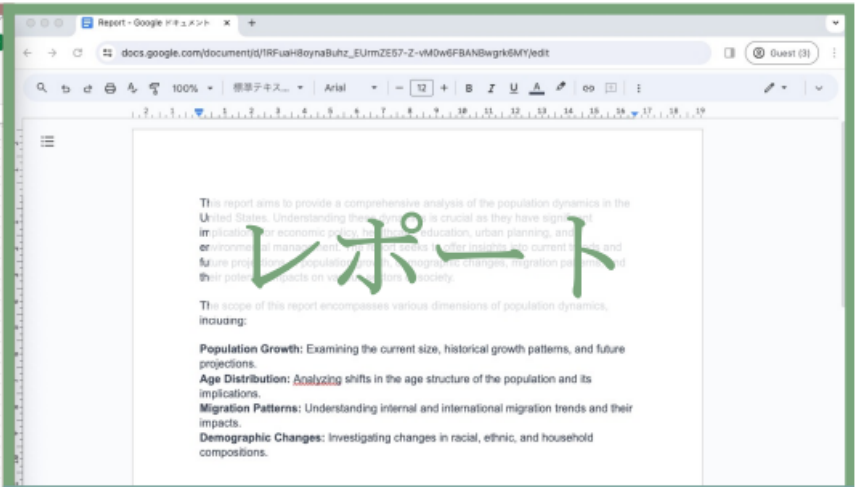
レポート

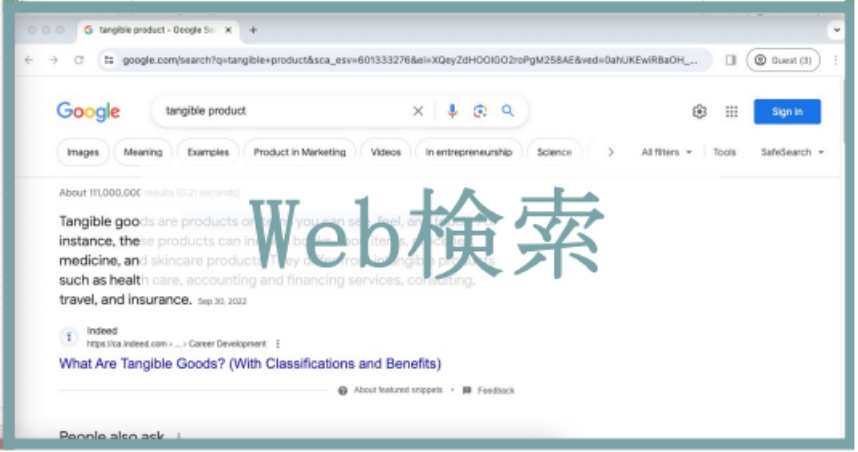
Web検索

RQ1: スプレッドシートを用いたデータ解析中にどのような情報要求が生まれるのか？

データ解析の情報行動の分類法やシステムに関する 85 本の論文を収集し，先行研究から 5 つのカテゴリからなる仮の分類法を構築した

カテゴリ	概要
テキスト	表中の単語の意味に関する要求
データ	閲覧している表に含まれていない表に関する要求
メタデータ	表の出典元や作成方法などの表自体の情報に関する要求
知見	知見の根拠となる文献およびデータに関する要求
分析方法	データ解析の方法に関する要求

分類の改善

仮の分類法でインタビューを実施

2人の著者がそれぞれ独立してインタビューの記録を分類し、新たな分類法を構築

新たな分類法をお互いに見せあい、議論を行い、最終的な分類法を構築

→ 5つのカテゴリから 6つのカテゴリに変更

カテゴリ	情報要求	#	事例
テキスト	用語の意味や詳細（事例や属性，他の用語との関連を含む）	108	無形商品って何？
数値	単位の意味や変換	15	推定日射量の単位を知りたい．
メタデータ	表の説明文（データの出所や収集方法を含む）	58	データはいつ収集された?，このデータの概要は？
データ傾向	表データの代表値（特定の計算によって得られる数値）や表データの一部分（特定の操作によって得られるデータ）	72	児童の各年齢の全体に占める割合を知りたい，各アイテムの年次推移を知りたい．
根拠	データの傾向の理由や根拠となる記事や一般知識もしくは関連する表データ	130	新潟の降雪量が多いことを裏付ける記事は？，日本の地価が下がっているかどうかを知りたい．
解析方法	データ分析における宣言的知識や手続的知識	41	このデータをどうやって可視化したら良いかわからない． エクセルで平均値を計算する方法を知りたい．

カテゴリ別の主観難易度

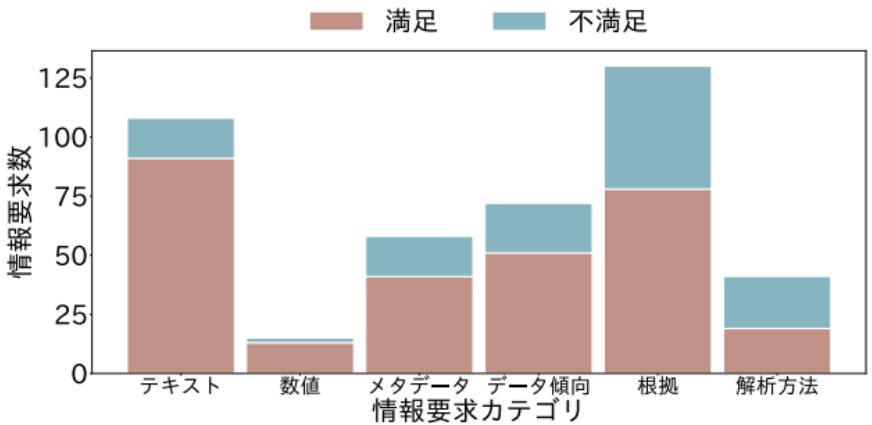

図 2: 各カテゴリの情報要求の分布．赤い棒は満足された情報要求を示し，青い棒は満足されていない情報要求を示している．

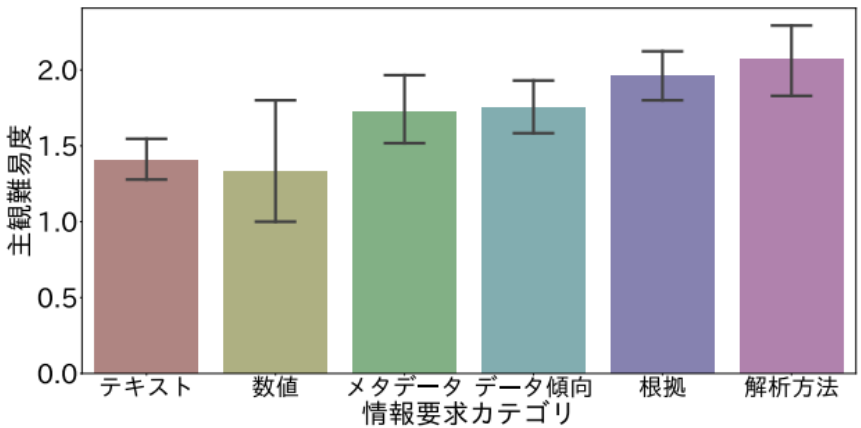

図 3: 情報要求を満たすための主観難易度の平均値．図中のエラーバーは標準誤差を表している．

`根拠` や `解析方法` のカテゴリが難易度が高い

RQ2: スプレッドシートを用いたデータ解析中の情報要求を満たすためにユーザはどのように検索するのか？

Web検索の利用に優位な差が見られた

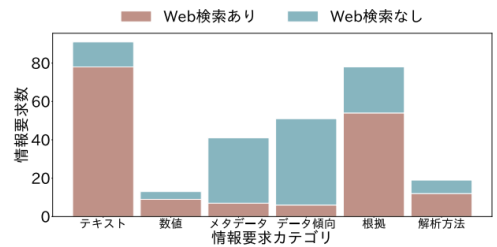

図 4: 検索を行って満たした情報要求と検索を行わずに満たした情報要求の分布.

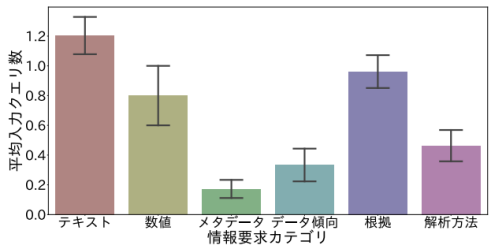

図 5: 1 つの情報要求あたりの平均入力クエリ数.

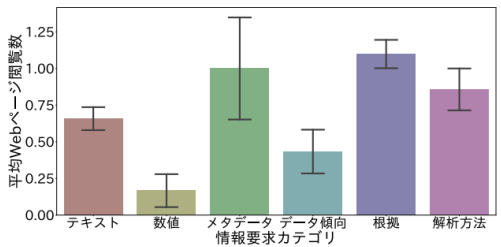

図 6: 1 クエリあたりの平均 Web ページ閲覧回数.

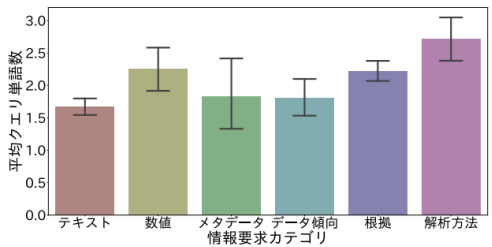

図 7: 1 クエリあたりの平均単語数.

分析

- `テキスト` と `根拠` カテゴリ → Web 検索 多
- `メタデータ` と `データ傾向` カテゴリ → Web 検索 少

`テキスト` と `根拠` カテゴリを満たすための情報が Web 上に多い

反対に, `メタデータ` と `データ傾向` カテゴリを満たすための情報がスプレッドシートに含まれることが多い

ユーザー行動と情報要求の満足度を明らかにする

ユーザ行動と情報要求の満足との相関の程度を明らかにするために，ロジスティック回帰分析を実施

- 目的変数: ユーザの満足を示すバイナリ変数
- 説明変数: 情報要求が生まれたセグメントで，どのユーザ行動が見られたかを示すバイナリ変数

Web検索とスプシを読むときに情報要求が生まれると，ユーザの満足度が高い

表 2: 情報要求の満足に関する回帰分析の結果．“変数” は切片と説明変数を示し，“相関” 列は相関係数を示している．太字の変数は有意な相関係数が見られた変数である（$p < 0.05$）．

$R^2 = 0.03696$		$p = 0.01296$	
変数	**相関係数**	**標準誤差**	p
（切片）	0.0994	0.279	0.722
データを探す	0.3259	0.317	0.303
ダウンロード	0.4546	0.701	0.517
読む	**0.7131**	**0.292**	**0.015**
質問	0.0999	0.395	0.800
操作	0.7285	0.472	0.122
可視化	-0.1679	0.353	0.635
Web 検索	**0.9520**	**0.294**	**0.001**
レポート	0.4088	0.391	0.295

RQ3: スプレッドシートを用いたデータ解析において，いつ情報要求が生まれるのか？

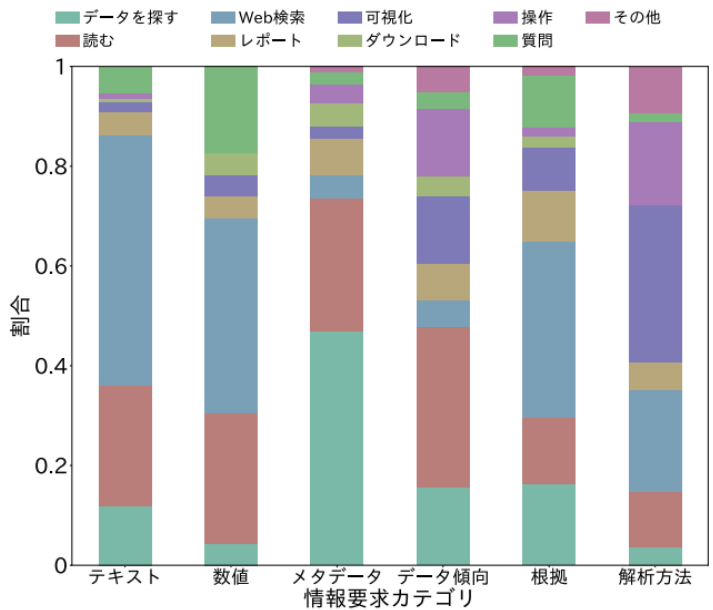

情報要求に対するユーザー行動は異なる傾向

情報要求と遷移確率

表 3: 情報要求の遷移確率．左の列は遷移前，上の行は遷移後のカテゴリを示している．▲ は残差分析により有意に高い確率を示しており（$p < 0.05$），▽ は有意に低い確率を示している（$p < 0.05$）．

前　後	テキスト	数値	メタ	傾向	根拠	解析
テキスト	▲0.396	0.019	0.123	0.142	▽0.264	0.057
数値	0.267	0.000	0.133	0.200	0.200	0.200
メタ	0.236	0.055	▲0.236	0.182	0.236	0.055
傾向	0.254	0.060	0.060	▲0.299	0.209	0.119
根拠	0.107	0.036	0.080	▽0.152	▲0.545	0.080
解析	0.147	0.059	0.088	0.118	0.265	▲0.324

同じカテゴリの情報要求は続けて発生しやすい

→ まとめて情報を探す。(e.g: スプシの使い方を調べる→データ分析の方法を調べる などは少ない)

結論(再掲)

まとめ 24

研究目的

スプレッドシートを用いたデータ解析中に生まれる情報要求の調査

手法: ユーザ実験を行いデータを収集し，収録映像をコーディング

分析結果

1. 6種類の情報要求（テキスト，数値，メタデータ，データ傾向，根拠，解析方法）があり，それぞれの要求を満たすための難易度は異なっている
2. ユーザはカテゴリごとに異なる検索行動をとり，特に「根拠」と「解析方法」を満たすために，異なる困難に直面する
3. 生まれるタイミングはユーザ行動（Web検索，スプレッドシート閲覧など）と関係がある

考察

ユーザの行動から生まれやすい情報要求カテゴリを特定し，そのカテゴリを満たすための情報を提供することが効果的なデータ解析につながる

出典: Zoom発表資料

感想

- 情報要求に対して、Web検索という行動は多く発生する
- 逆に、Web検索で満たされない情報要求はスプレッドシートに含まれることが多い(メタデータ)
- 複雑な情報がほしいときはクエリが長くなる → 生成系AIが適切なクエリに表現し直したりしたら面白そう
- Web検索が多いけど、実際に情報要求ごとの滞在時間やサイトの特徴を調べてみたい
- 先行研究の内容で面白そうなのがいくつかあった
  - ユーザの行動に基づいて検索効果を向上させる研究
  - 複雑な検索タスクにおけるユーザの行動を調査した研究
- この研究のスコープをWeb検索に絞り、具体的なサイトの特徴を調査する研究も面白そう